

Machine Learning & Data Analysis

Dari Pelaporan Deskriptif ke Prediktif

Materi pelatihan · 5 modul · dilengkapi latihan iPython Notebook & dataset



PENGANTAR

Tujuan & Manfaat Pelatihan



TUJUAN

Transformasi dari pelaporan deskriptif ke prediktif, serta menggunakan pola data historis untuk memprediksi angka masa depan secara akurat.



MANFAAT UMUM

Meningkatkan ketajaman analisis melalui data — pengambilan keputusan berbasis data (data-driven decision).



MANFAAT KHUSUS

Akurasi forecasting yang lebih tinggi dan kemampuan deteksi anomali transaksi.

MATERI TRAINING

Lima Modul Pembelajaran

1

Pemanfaatan algoritma AI untuk pengolahan data

Fondasi: mengenali, membersihkan, dan merangkum data.

2

Logika machine learning secara sederhana

Mesin belajar dari data historis: fit → predict → evaluasi.

3

Teknik klasifikasi dan prediksi

Menjawab “kategori apa?” dan “berapa angkanya?”

4

Cara AI mendeteksi keanehan data (anomali)

Menyaring transaksi tidak wajar secara otomatis.

5

Interpretasi hasil analisis AI untuk bisnis


Dari output model menjadi keputusan manajemen.



Format Sesi

Teori singkat, demo, lalu hands-on Python dengan dataset latihan untuk setiap modul.


Naik Level: dari Deskriptif ke Prediktif



Fokus pelatihan ini: membangun kemampuan PREDIKTIF — dan itu dimulai dari data yang diolah dengan benar.

MODUL 1 · PENGOLAHAN DATA

Alur Kerja Pengolahan Data



“Garbage In, Garbage Out”

Data kotor menghasilkan analisis dan prediksi yang salah. Pembersihan data adalah fondasi semua modul berikutnya.

Hasil latihan modul 1

- 1.218 baris mentah → 1.185 bersih
- 18 duplikat & 15 qty kosong dibuang
- 30 penulisan part dirapikan

Mesin Belajar Seperti Manusia Belajar



Manusia

Belajar dari PENGALAMAN → mengambil keputusan. Makin banyak pengalaman, makin tajam intuisinya.



Mesin (ML)

Belajar dari DATA HISTORIS → membuat prediksi. Tidak diprogram aturan satu per satu; ia menemukan pola sendiri.

Tiga istilah yang wajib dipahami

FITUR (X)

Informasi yang kita ketahui. Contoh: bulan ke-, ada promo, penghasilan konsumen.

TARGET (y)

Hal yang ingin diprediksi. Contoh: unit terjual, status kredit Lancar/Macet.

MODEL

“Rumus pola” hasil belajar dari pasangan X dan y pada data historis.

Resep Baku ML — Selalu Empat Langkah

1 Siapkan X & y

Tentukan fitur dan target dari data historis

2 Bagi data

Data latih untuk belajar, data uji untuk ujian

3 `model.fit()`

Mesin belajar menemukan pola

4 `model.predict()`

Prediksi data baru, lalu ukur akurasi

```
02_logika_ml_sederhana.py
```

```
model = LinearRegression()
model.fit(X_latih, y_latih)
prediksi = model.predict(X_uji)
# akurasi praktis ± 92%
```



Aturan Emas

Model wajib diuji pada data yang BELUM pernah dilihatnya. Nilai bagus hanya di data latih = overfitting (“menghafal soal”), bukan benar-benar pintar.

Linear Regression — Garis Terbaik

1 Petakan hubungan

Hubungkan fitur X (mis. bulan, harga) ke angka target y (unit terjual).

2 Garis terbaik


Cari garis $y = a + b \cdot X$ dengan total jarak ke semua titik paling kecil (least squares).

3 Prediksi angka

Masukkan nilai X baru ke garis untuk memperkirakan angka y.

```
03_klasifikasi_dan_prediksi.py

from sklearn.linear_model import (
    LinearRegression)
model = LinearRegression()
model.fit(X_latih, y_latih)
y_pred = model.predict(X_baru)
```



Kelebihan & batas: cepat dan mudah dibaca — koefisien b menunjukkan arah & besar pengaruh tiap fitur; namun hanya menangkap pola garis lurus.

Dua Pertanyaan Bisnis, Dua Teknik



KLASIFIKASI

Memprediksi KATEGORI / label

- Kredit konsumen: Lancar atau Macet?
- Transaksi: wajar atau mencurigakan?
- Konsumen servis: bertahan atau berhenti (churn)?

Demo: prediksi risiko kredit — akurasi 86%



REGRESI / FORECASTING

Memprediksi ANGKA

- Berapa unit motor terjual bulan depan?
- Berapa kebutuhan stok part kuartal depan?
- Berapa estimasi biaya garansi tahun ini?

Demo: forecast penjualan 6 bulan ke depan

Algoritma populer — Decision Tree, Random Forest, Linear Regression — semuanya mengikuti resep yang sama: fit → predict.

Random Forest Classifier — Voting

1 Banyak pohon

Bangun ratusan decision tree, tiap pohon dari sampel data & fitur yang diacak.

2 Tiap pohon vote

Setiap pohon memberi satu suara kelas, mis. Lancar atau Macet.


3 Voting mayoritas

Kelas dengan suara terbanyak jadi prediksi akhir — lebih stabil dari satu pohon.


```
03_klasifikasi_dan_prediksi.py

from sklearn.ensemble import (
    RandomForestClassifier)
clf = RandomForestClassifier(
    n_estimators=300)
clf.fit(X_latih, y_latih)
kelas = clf.predict(X_baru)
```

Kelebihan & batas: akurat dan tahan overfitting karena menggabungkan banyak pohon; namun lebih lambat dan tak sesederhana satu garis untuk dibaca.



Random Forest for Classification (and Prediction)



Random Forest Regressor — Rata-rata

1 Banyak pohon

Ratusan decision tree dilatih pada sampel data acak yang berbeda-beda.

2 Pohon → angka

Setiap pohon menghasilkan satu perkiraan angka secara mandiri.


3 Rata-ratakan

Prediksi akhir = rata-rata semua pohon — hasil mulus & tahan pencilan (outlier).


```
03_klasifikasi_dan_prediksi.py

from sklearn.ensemble import (
    RandomForestRegressor)
reg = RandomForestRegressor(
    n_estimators=300)
reg.fit(X_latih, y_latih)
angka = reg.predict(X_baru)
```

Kelebihan & batas: menangkap pola tak-linear & interaksi antar-fitur tanpa rumus manual; namun hasilnya lebih sulit dijelaskan dari sekadar garis lurus.



Demo: Forecast Penjualan 6 Bulan ke Depan



103.247

unit — proyeksi total Jun–Nov 2026,
dasar rencana produksi & stok

±7,7%

rata-rata meleset (MAE) saat model
diuji pada 10 bulan terakhir

2 skenario

promo (Juli & November) ikut dihitung
di dalam prediksi

MODUL 4 · DETEKSI ANOMALI

Menemukan Keanehan di Ribuan Transaksi

Anomali = data yang menyimpang jauh dari pola umum: salah input, transaksi mencurigakan, atau kejadian luar biasa yang perlu ditindaklanjuti.



Z-SCORE

Statistik dasar

Seberapa jauh nilai dari rata-rata, diukur dalam simpangan baku. $|z| > 3$ → patut dicurigai.



IQR

Pagar kuartil

Logika boxplot: nilai di luar $1,5 \times$ rentang kuartil dianggap pencilan. Sederhana & cepat.



ISOLATION FOREST

Machine learning

Melihat beberapa kolom SEKALIGUS (qty, harga, total) dan tidak butuh data berlabel.

Mulailah dari metode sederhana — sering kali sudah cukup. Naik ke ML saat pola makin kompleks.

Isolation Forest — Mengisolasi Anomali

1 Pisahkan acak

Bangun ratusan pohon; tiap cabang memotong data pada fitur & nilai potong yang dipilih acak.

2 Hitung kedalaman


Catat berapa potongan dibutuhkan untuk mengisolasi tiap titik (panjang lintasan).

3 Skor anomali

Lintasan pendek = cepat terisolasi = anomali; lintasan panjang = normal.

```
04_deteksi_anomali.py

from sklearn.ensemble import (
    IsolationForest)
iso = IsolationForest(
    contamination=0.01)
label = iso.fit_predict(X)
# -1 = anomali, 1 = normal
```



Kelebihan & batas: tanpa label & menilai banyak kolom sekaligus, cepat untuk data besar; namun ambang kontaminasi perlu disetel dan hasilnya = daftar prioritas, bukan vonis.

MODUL 4 · DETEKSI ANOMALI

Demo: AI Menyaring, Manusia Memverifikasi

ID Transaksi	Part	Temuan AI
TRX100015	Oli Mesin	Qty 88 — normalnya ~4 per transaksi
TRX100120	Ban Luar	Harga 12× lipat dari harga normal
TRX100830	Busi	Harga Rp1.000 — hampir nol (potensi fraud)
TRX100183	Kampas Rem	Harga 11× lipat dari harga normal

Cuplikan nyata dari output 04_deteksi_anomali.py (data sintetis).

Output AI = daftar PRIORITAS untuk dicek — bukan vonis. Keputusan akhir tetap pada manusia.

1.218

transaksi diperiksa otomatis



12 (1%)


ditandai paling aneh oleh AI



Verifikasi

tim memeriksa & menindaklanjuti

Membuka “Kotak Hitam”: Faktor Pendorong



Faktor dominan

Penghasilan & riwayat telat → wajib divalidasi sungguh-sungguh saat survei konsumen.

Faktor menengah

Besaran DP → bisa jadi alat kebijakan: syarat DP minimum untuk segmen berisiko.

Faktor kecil

Tenor → jangan dijadikan dasar keputusan utama.

Terjemahkan Metrik ke Bahasa Manajemen

86%

akurasi model risiko kredit pada 300 data uji

Rp612 jt

potensi kerugian kredit macet yang berhasil dicegah

Rp24 jt

trade-off: margin hilang karena salah menolak 16 calon

Angka ilustrasi dari latihan modul 5 (asumsi kerugian Rp9 jt/kredit macet, margin Rp1,5 jt/konsumen).



Checklist komunikasi hasil

- Dampak dalam rupiah, bukan sekadar akurasi
- Rekomendasi tindakan yang jelas
- Batasan model disampaikan jujur



Batasan yang wajib diingat

- Korelasi $\neq$ sebab-akibat
- Pola masa lalu bisa berubah → evaluasi berkala
- Model = alat bantu; keputusan tetap manusia

PRAKTIK

Paket Latihan Hands-On iPython Notebook

- 1** **01_pengolahan_data.ipynb**
Bersihkan & rangkum 1.218 transaksi sparepart
- 2** **02_logika_ml_sederhana.ipynb**
Resep fit → predict pada data penjualan
- 3** **03_klasifikasi_dan_prediksi.ipynb**
Risiko kredit + forecast 6 bulan
- 4** **04_deteksi_anomali.ipynb**
Z-score, IQR & Isolation Forest
- 5** **05_interpretasi_bisnis.ipynb**
Feature importance → ringkasan eksekutif



data_penjualan_motor.csv

53 bulan riwayat penjualan



data_transaksi_sparepart.csv

1.218 transaksi, sengaja “kotor”



data_kredit_konsumen.csv

1.500 profil konsumen kredit

```
pip install pandas numpy  
scikit-learn matplotlib
```

Lima Hal untuk Dibawa Pulang

- 1 Data bersih adalah fondasi — garbage in, garbage out.
- 2 ML = belajar pola dari data historis: fit → predict → evaluasi.
- 3 Pertanyaan kategori → klasifikasi; pertanyaan angka → forecasting.
- 4 AI menyaring anomali; manusia memverifikasi & memutuskan.
- 5 Sampaikan hasil dalam rupiah, rekomendasi, dan batasannya.

Langkah berikutnya: terapkan pola latihan pada satu dataset nyata dari area kerja Anda dalam 2 minggu ke depan.

