

Machine Learning & Data Analysis

Dari Pelaporan Deskriptif ke Prediktif

Materi pelatihan · 5 modul · dilengkapi latihan iPython Notebook & dataset



PENGANTAR

Tujuan & Manfaat Pelatihan



TUJUAN

Transformasi dari pelaporan deskriptif ke prediktif, serta menggunakan pola data historis untuk memprediksi angka masa depan secara akurat.



MANFAAT UMUM

Meningkatkan ketajaman analisis melalui data — pengambilan keputusan berbasis data (data-driven decision).



MANFAAT KHUSUS

Akurasi forecasting yang lebih tinggi dan kemampuan deteksi anomali transaksi.

MATERI TRAINING

Lima Modul Pembelajaran

1

Pemanfaatan algoritma AI untuk pengolahan data

Fondasi: mengenali, membersihkan, dan merangkum data.

2

Logika machine learning secara sederhana

Mesin belajar dari data historis: fit → predict → evaluasi.

3

Teknik klasifikasi dan prediksi

Menjawab “kategori apa?” dan “berapa angkanya?”

4

Cara AI mendeteksi keanehan data (anomali)

Menyaring transaksi tidak wajar secara otomatis.

5

Interpretasi hasil analisis AI untuk bisnis

Dari output model menjadi keputusan manajemen.



Format Sesi

Teori singkat, demo, lalu hands-on Python dengan dataset latihan untuk setiap modul.

Naik Level: dari Deskriptif ke Prediktif

DESKRIPTIF

Apa yang terjadi?

Rekap penjualan bulanan

DIAGNOSTIK

Mengapa terjadi?

Analisis penurunan di satu wilayah

PREDIKTIF

Apa yang akan terjadi?

Forecast unit bulan depan

PRESKRIPSTIF


Apa yang harus dilakukan?

Rekomendasi stok & promo

Fokus pelatihan ini: membangun kemampuan PREDIKTIF — dan itu dimulai dari data yang diolah dengan benar.

MODUL 1 · PENGOLAHAN DATA

Alur Kerja Pengolahan Data



“Garbage In, Garbage Out”

Data kotor menghasilkan analisis dan prediksi yang salah. Pembersihan data adalah fondasi semua modul berikutnya.

Hasil latihan modul 1

- 1.218 baris mentah → 1.185 bersih
- 18 duplikat & 15 qty kosong dibuang
- 30 penulisan part dirapikan

Mesin Belajar Seperti Manusia Belajar



Manusia

Belajar dari PENGALAMAN → mengambil keputusan. Makin banyak pengalaman, makin tajam intuisinya.



Mesin (ML)

Belajar dari DATA HISTORIS → membuat prediksi. Tidak diprogram aturan satu per satu; ia menemukan pola sendiri.

Tiga istilah yang wajib dipahami

FITUR (X)

Informasi yang kita ketahui. Contoh: bulan ke-, ada promo, penghasilan konsumen.

TARGET (y)

Hal yang ingin diprediksi. Contoh: unit terjual, status kredit Lancar/Macet.

MODEL

“Rumus pola” hasil belajar dari pasangan X dan y pada data historis.

Dua Paradigma: Supervised vs Unsupervised



SUPERVISED

Belajar dengan kunci jawaban (label y)

- Data berlabel: tiap baris punya fitur X dan target y yang sudah diketahui
- Tujuan: pelajari pola $X \rightarrow y$, lalu prediksi y untuk data baru
- Tugas: klasifikasi (kategori) & regresi (angka)

Contoh: risiko kredit, forecast penjualan → Modul 3



UNSUPERVISED

Belajar tanpa kunci jawaban (tanpa label)

- Data tanpa label: hanya ada fitur X, tidak ada target y
- Tujuan: temukan sendiri pola atau struktur tersembunyi
- Tugas: clustering (pengelompokan) & deteksi anomali

Contoh: segmentasi konsumen, anomali transaksi → Modul 4

Pertanyaan kunci: adakah “jawaban benar” (label y) untuk dipelajari? Ada → supervised; tidak ada → unsupervised.

Peta Teknik: Dari Paradigma ke Tugas



Fokus pelatihan: klasifikasi & regresi (Modul 3) dan deteksi anomali (Modul 4); clustering sebagai pengayaan.

Resep Baku ML — Selalu Empat Langkah

1 Siapkan X & y

Tentukan fitur dan target dari data historis

2 Bagi data

Data latih untuk belajar, data uji untuk ujian

3 model.fit()

Mesin belajar menemukan pola

4 model.predict()

Prediksi data baru, lalu ukur akurasi

```
02_logika_ml_sederhana.py
```

```
model = LinearRegression()  
model.fit(X_latih, y_latih)  
prediksi = model.predict(X_uji)  
# akurasi praktis ± 92%
```



Aturan Emas

Model wajib diuji pada data yang BELUM pernah dilihatnya. Nilai bagus hanya di data latih = overfitting (“menghafal soal”), bukan benar-benar pintar.

Linear Regression — Garis Terbaik

1 Petakan hubungan

Hubungkan fitur X (mis. bulan, harga) ke angka target y (unit terjual).

2 Garis terbaik


Cari garis $y = a + b \cdot X$ dengan total jarak ke semua titik paling kecil (least squares).

3 Prediksi angka

Masukkan nilai X baru ke garis untuk memperkirakan angka y.

```
03_klasifikasi_dan_prediksi.py

from sklearn.linear_model import (
    LinearRegression)
model = LinearRegression()
model.fit(X_latih, y_latih)
y_pred = model.predict(X_baru)
```



Kelebihan & batas: cepat dan mudah dibaca — koefisien b menunjukkan arah & besar pengaruh tiap fitur; namun hanya menangkap pola garis lurus.

Dua Pertanyaan Bisnis, Dua Teknik



KLASIFIKASI

Memprediksi KATEGORI / label

- Kredit konsumen: Lancar atau Macet?
- Transaksi: wajar atau mencurigakan?
- Konsumen servis: bertahan atau berhenti (churn)?

Demo: prediksi risiko kredit — akurasi 86%



REGRESI / FORECASTING

Memprediksi ANGKA

- Berapa unit motor terjual bulan depan?
- Berapa kebutuhan stok part kuartal depan?
- Berapa estimasi biaya garansi tahun ini?

Demo: forecast penjualan 6 bulan ke depan

Algoritma populer — Decision Tree, Random Forest, Linear Regression — semuanya mengikuti resep yang sama: fit → predict.

Random Forest Classifier — Voting

1 Banyak pohon

Bangun ratusan decision tree, tiap pohon dari sampel data & fitur yang diacak.

2 Tiap pohon vote

Setiap pohon memberi satu suara kelas, mis. Lancar atau Macet.

3 Voting mayoritas

Kelas dengan suara terbanyak jadi prediksi akhir — lebih stabil dari satu pohon.


```
03_klasifikasi_dan_prediksi.py

from sklearn.ensemble import (
    RandomForestClassifier)
clf = RandomForestClassifier(
    n_estimators=300)
clf.fit(X_latih, y_latih)
kelas = clf.predict(X_baru)
```

Kelebihan & batas: akurat dan tahan overfitting karena menggabungkan banyak pohon; namun lebih lambat dan tak sesederhana satu garis untuk dibaca.



Random Forest for Classification (and Prediction)



Random Forest Regressor — Rata-rata

1 Banyak pohon

Ratusan decision tree dilatih pada sampel data acak yang berbeda-beda.

2 Pohon → angka

Setiap pohon menghasilkan satu perkiraan angka secara mandiri.


3 Rata-ratakan

Prediksi akhir = rata-rata semua pohon — hasil mulus & tahan pencilan (outlier).

```
03_klasifikasi_dan_prediksi.py

from sklearn.ensemble import (
    RandomForestRegressor)
reg = RandomForestRegressor(
    n_estimators=300)
reg.fit(X_latih, y_latih)
angka = reg.predict(X_baru)
```

Kelebihan & batas: menangkap pola tak-linear & interaksi antar-fitur tanpa rumus manual; namun hasilnya lebih sulit dijelaskan dari sekadar garis lurus.





±7,7%

2 skenario

promo (Juli & November) ikut dihitung
di dalam prediksi

MODUL 4 · DETEKSI ANOMALI

Menemukan Keanehan di Ribuan Transaksi

Anomali = data yang menyimpang jauh dari pola umum: salah input, transaksi mencurigakan, atau kejadian luar biasa yang perlu ditindaklanjuti.



Z-SCORE

Statistik dasar

Seberapa jauh nilai dari rata-rata, diukur dalam simpangan baku. $|z| > 3$ → patut dicurigai.



IQR

Pagar kuartil

Logika boxplot: nilai di luar $1,5 \times$ rentang kuartil dianggap pencilan. Sederhana & cepat.



ISOLATION FOREST

Machine learning

Melihat beberapa kolom SEKALIGUS (qty, harga, total) dan tidak butuh data berlabel.

Mulailah dari metode sederhana — sering kali sudah cukup. Naik ke ML saat pola makin kompleks.

Isolation Forest — Mengisolasi Anomali

1 Pisahkan acak

Bangun ratusan pohon; tiap cabang memotong data pada fitur & nilai potong yang dipilih acak.

2 Hitung kedalaman


Catat berapa potongan dibutuhkan untuk mengisolasi tiap titik (panjang lintasan).

3 Skor anomali

Lintasan pendek = cepat terisolasi = anomali; lintasan panjang = normal.

```
04_deteksi_anomali.py

from sklearn.ensemble import (
    IsolationForest)
iso = IsolationForest(
    contamination=0.01)
label = iso.fit_predict(X)
# -1 = anomali, 1 = normal
```



Kelebihan & batas: tanpa label & menilai banyak kolom sekaligus, cepat untuk data besar; namun ambang kontaminasi perlu disetel dan hasilnya = daftar prioritas, bukan vonis.

MODUL 4 · DETEKSI ANOMALI

Demo: AI Menyaring, Manusia Memverifikasi

ID Transaksi	Part	Temuan AI
TRX100015	Oli Mesin	Qty 88 — normalnya ~4 per transaksi
TRX100120	Ban Luar	Harga 12× lipat dari harga normal
TRX100830	Busi	Harga Rp1.000 — hampir nol (potensi fraud)
TRX100183	Kampas Rem	Harga 11× lipat dari harga normal

Cuplikan nyata dari output 04_deteksi_anomali.py (data sintetis).

Output AI = daftar PRIORITAS untuk dicek — bukan vonis. Keputusan akhir tetap pada manusia.

1.218

transaksi diperiksa otomatis



12 (1%)

ditandai paling aneh oleh AI




Verifikasi

tim memeriksa & menindaklanjuti

Membuka “Kotak Hitam”: Faktor Pendorong

Faktor penentu risiko kredit (model demo, data sintetis)



Faktor dominan

Penghasilan & riwayat telat → wajib divalidasi sungguh-sungguh saat survei konsumen.

Faktor menengah

Besaran DP → bisa jadi alat kebijakan: syarat DP minimum untuk segmen berisiko.

Faktor kecil

Tenor → jangan dijadikan dasar keputusan utama.

Terjemahkan Metrik ke Bahasa Manajemen

86%

akurasi model risiko kredit pada 300 data uji

Rp612 jt

potensi kerugian kredit macet yang berhasil dicegah

Rp24 jt

trade-off: margin hilang karena salah menolak 16 calon

Angka ilustrasi dari latihan modul 5 (asumsi kerugian Rp9 jt/kredit macet, margin Rp1,5 jt/konsumen).



Checklist komunikasi hasil

- Dampak dalam rupiah, bukan sekadar akurasi
- Rekomendasi tindakan yang jelas
- Batasan model disampaikan jujur



Batasan yang wajib diingat

- Korelasi $\neq$ sebab-akibat
- Pola masa lalu bisa berubah → evaluasi berkala
- Model = alat bantu; keputusan tetap manusia

PRAKTIK

Paket Latihan Hands-On iPython Notebook

1

01_pengolahan_data.ipynb

Bersihkan & rangkum 1.218 transaksi sparepart

2

02_logika_ml_sederhana.ipynb

Resep fit → predict pada data penjualan

3

03_klasifikasi_dan_prediksi.ipynb

Risiko kredit + forecast 6 bulan

4

04_deteksi_anomali.ipynb

Z-score, IQR & Isolation Forest

5

05_interpretasi_bisnis.ipynb

Feature importance → ringkasan eksekutif



data_penjualan_motor.csv

53 bulan riwayat penjualan



data_transaksi_sparepart.csv

1.218 transaksi, sengaja “kotor”



data_kredit_konsumen.csv

1.500 profil konsumen kredit

```
pip install pandas numpy  
scikit-learn matplotlib
```

Lima Hal untuk Dibawa Pulang

- 1 Data bersih adalah fondasi — garbage in, garbage out.
- 2 ML = belajar pola dari data historis: fit → predict → evaluasi.
- 3 Pertanyaan kategori → klasifikasi; pertanyaan angka → forecasting.
- 4 AI menyaring anomali; manusia memverifikasi & memutuskan.
- 5 Sampaikan hasil dalam rupiah, rekomendasi, dan batasannya.

Langkah berikutnya: terapkan pola latihan pada satu dataset nyata dari area kerja Anda dalam 2 minggu ke depan.

