

Natural Language Processing (NLP)

Memahami dan mengotomasi pengolahan serta pemahaman data berbasis teks dengan kecerdasan buatan.

MODUL 4

HANDS-ON PYTHON



PENDAHULUAN

Tujuan & Manfaat Training



TUJUAN

Memahami cara AI berinteraksi, menganalisis, dan mengekstraksi makna dari informasi tidak terstruktur, serta mampu melakukan otomasi pengolahan dan pemahaman data berbasis teks.



MANFAAT UMUM

Efisiensi waktu dalam pengolahan dokumen dengan volume yang besar.



MANFAAT KHUSUS

Mempercepat pencarian informasi penting dalam dokumen atau laporan pada business process.

AGENDA

Empat Materi Training



MATERI 1

Ekstraksi Data & Analisis Teks Otomatis

Mengubah dokumen menjadi data terstruktur



MATERI 2

Cara Kerja AI Memahami Teks

Dari kata menjadi angka yang dipahami mesin



MATERI 3

Ekstraksi Poin Penting dari Dokumen

Kata kunci, entitas, dan ringkasan otomatis



MATERI 4

Pencarian Informasi pada Kumpulan Data

Mesin pencari mini untuk dokumen internal



Setiap materi memiliki notebook Python (.ipynb) tersendiri — 4 notebook praktik siap dijalankan di Google Colab / Jupyter.

PENGANTAR

Apa itu Natural Language Processing?

NLP adalah cabang kecerdasan buatan (AI) yang membuat komputer mampu **membaca, memahami, dan mengolah bahasa manusia.**



Analogi: mengajari komputer “membaca” dokumen seperti manusia — dengan kecepatan ribuan dokumen per menit.

±80%

data di perusahaan berbentuk tidak terstruktur: email, dokumen, laporan, chat.

NLP DI SEKITAR KITA



Google Translate

Menerjemahkan antarbahasa secara instan



Chatbot layanan pelanggan

Menjawab pertanyaan otomatis 24 jam



Filter spam email

Memilah pesan penting vs sampah



Asisten suara

Memahami perintah lisan (Siri, Google)

MATERI 1

Dari Dokumen Menjadi Data: Ekstraksi Otomatis



CARA MANUAL

Dokumen dibaca dan disalin satu per satu — lambat, rawan salah ketik, dan membosankan.



DENGAN NLP

Komputer membaca teks lalu menarik data penting secara otomatis — ribuan dokumen selesai dalam hitungan menit.



Representasi of unstructured text as horizontal lines.

Teks bebas (invoice)



No. Inv	INV-00123
Tanggal	15/06/26
Total	Rp 2,75 jt

Data terstruktur

Satu pola ekstraksi → berlaku untuk ribuan dokumen: itulah kekuatan otomasi.

MATERI 1

Empat Analisis Teks Otomatis di Dunia Kerja



Ekstraksi Informasi

Menarik nomor, tanggal, email, dan nominal dari dokumen. Contoh: input data invoice otomatis.



Analisis Frekuensi Kata

Menemukan topik yang paling sering dibicarakan. Contoh: keluhan terbanyak pelanggan AHASS.



Analisis Sentimen

Menilai teks positif / negatif secara otomatis. Contoh: monitoring kepuasan dari feedback.



Klasifikasi Dokumen

Memilah dokumen ke kategori yang tepat. Contoh: memisahkan email komplain vs penawaran.

MATERI 1

Regex: Bahasa Pola dalam 5 Menit

SIMBOL DASAR

Simbol	Arti	Cocok dengan
<code>\d</code>	satu digit angka	2, 6
<code>\d{4}</code>	tepat 4 digit	2026
<code>\w+</code>	huruf / angka	Honda, MPX2
<code>+</code>	satu kali atau lebih	123456
<code>[.-]</code>	salah satu karakter	. atau -

POLA SIAP PAKAI

`r"INV-\d{4}-\d{5}"`
menemukan: INV-2026-00123


`r"Rp\s?[\d.]+"`
menemukan: Rp 2.750.000

`r"[\w.+ -]+@[ \w- ]+\.\w+"`
menemukan: maju.jaya@email.com

Sekali pola dibuat → berlaku untuk semua dokumen dengan format yang sama.

MATERI 1

Alur Kerja Ekstraksi Dokumen Otomatis



Praktik — Notebook Materi 1: satu invoice menjadi tabel rapi dalam kurang dari 1 detik menggunakan `re.findall()`

MATERI 2

Bagaimana AI Memahami Teks?



Komputer tidak memahami kata — komputer hanya memahami ANGKA.



Teks Mentah

“Pelayanan sangat memuaskan!”



Preprocessing

Bersihkan & pecah menjadi kata



Jadi Angka

BoW · TF-IDF · embedding



Model AI

Belajar pola → prediksi & analisis

Semakin bersih teks dan semakin tepat representasi angkanya, semakin akurat hasil AI-nya.

MATERI 2

Preprocessing: Membersihkan Teks Tahap demi Tahap

KALIMAT ASLI

Pelayanan Bengkel AHASS sangat MEMUASKAN dan cepat!

1 • CASE FOLDING

pelayanan bengkel ahass sangat memuaskan dan cepat!

2 • TOKENISASI

pelayanan · bengkel · ahass · sangat · memuaskan · dan · cepat

3 • STOPWORD REMOVAL

pelayanan · bengkel · ahass · ~~sangat~~ · memuaskan · ~~dan~~ · cepat

4 • STEMMING

layan · bengkel · ahass · muas · cepat

Library Bahasa Indonesia untuk stopwords & stemming: [Sastrawi](#) · dipraktikkan langsung di notebook.

MATERI 2

Dari Kata Menjadi Angka: Bag of Words & TF-IDF

BAG OF WORDS — HITUNG KEMUNCULAN

Kalimat 1: "servis motor cepat"

Kalimat 2: "servis motor lama"

	servis	motor	cepat	lama
Kalimat 1	1	1	1	0
Kalimat 2	1	1	0	1

Setiap kalimat kini menjadi deretan angka (vektor) — bisa dihitung, dibandingkan, dan dipelajari oleh model AI.

TF-IDF — MEMBERI BOBOT KATA PENTING

Bobot TINGGI ↑ kata khas: sering di dokumen ini, jarang di dokumen lain (mis. "lama").

Bobot RENDAH ↓ kata umum yang muncul di mana-mana (mis. "motor").

Level lanjut — word embedding: kata bermakna mirip diwakili angka yang berdekatan. Inilah dasar model AI modern (LLM).

MATERI 2


Word Embedding: Peta Makna Kata

BoW & TF-IDF hanya mencocokkan kata yang **sama persis**.
Word embedding melangkah lebih jauh:

- Setiap kata menjadi titik pada “peta makna” berdimensi ratusan.
- Kata bermakna mirip → letaknya berdekatan (motor $\approx$ sepeda motor).
- Peta ini dipelajari otomatis dari miliaran kalimat.



Fondasi LLM & semantic search modern — diilustrasikan sebagai peta 2D di Notebook Materi 2.



Kata serupa mengelompok — komputer “melihat” kemiripan makna, walau ejaannya berbeda.

MATERI 3

Tiga Teknik Mengambil Poin Penting Dokumen



Ekstraksi Kata Kunci

Menemukan istilah terpenting dokumen berdasarkan bobot TF-IDF.

oli · mesin · penggantian



NER — Deteksi Entitas

Menandai tanggal, nominal uang, organisasi, dan jumlah secara otomatis.

15 Juni 2026 · Rp 1,2 M



Peringkasan Otomatis

Memilih kalimat inti sehingga dokumen panjang cepat dipahami.

3 halaman → 3 kalimat

MATERI 3

NER: Komputer Menandai Informasi Penting

Pada **15 Juni 2026**, **PT Astra Honda Motor** mengirim **250 unit** sparepart senilai **Rp 1.200.000.000** ke dealer di **Surabaya**.

TANGGAL

ORGANISASI

JUMLAH

UANG

LOKASI



Cara membuatnya: versi sederhana memakai pola regex — contoh `r"Rp\s?[\d.]+"` untuk mendeteksi UANG. Versi industri memakai model NLP (spaCy / transformer) yang mengenali entitas tanpa pola manual.

MATERI 3

Peringkasan Otomatis: Dokumen Panjang Jadi Singkat

1

Hitung frekuensi kata

kata penting di seluruh dokumen (tanpa stopword).

2

Skor setiap kalimat

jumlah frekuensi dari kata-kata di dalamnya.

3

Ambil skor tertinggi

kalimat terbaik menjadi ringkasan, urutan asli terjaga.

Ekstraktif = memilih kalimat asli · **Abstraktif** = menulis ulang (LLM)



Dokumen asli

Ringkasan

Kalimat terpenting dipilih otomatis dari dokumen asli.

MATERI 4

Mesin Pencari untuk Dokumen Internal Perusahaan

Information Retrieval: menemukan dokumen yang tepat dari ribuan dokumen dalam hitungan detik — seperti Google, khusus untuk data internal.



Contoh koleksi dokumen internal:

SOP

Laporan Produksi

Panduan K3

Prosedur Garansi

Notulen Rapat

MATERI 4

Kata Persis vs Pencarian Berbobot (TF-IDF)


✗ **PENCARIAN KATA PERSIS**

Cepat & sederhana, tetapi gagal saat istilah berbeda: mencari “ganti oli” tidak menemukan “penggantian oli”.

✓ **TF-IDF + COSINE SIMILARITY**

Query & dokumen menjadi vektor angka → kemiripan dihitung → dokumen relevan tetap ditemukan beserta skor relevansinya.

SKOR KEMIRIPAN — QUERY: “jadwal ganti oli motor”



Hasil praktik notebook: dokumen paling relevan otomatis berada di urutan teratas.

MATERI 4

Lima Level Teknologi Pencarian

1

Kata kunci persis

hanya cocok jika teksnya sama persis — rapuh terhadap variasi kata

2

TF-IDF + cosine similarity

bobot kata + skor relevansi 0–1

PRAKTIK KITA

3

+ Stemming (Sastrawi)

variasi imbuhan ikut cocok: “ganti” = “penggantian”

PRAKTIK KITA

4

Semantic search (embedding)

paham makna: “motor tidak bisa distarter” → “troubleshooting pengapian”

5

RAG + LLM

chatbot yang menjawab pertanyaan langsung dari dokumen internal

Prinsip semua level tetap sama: teks → vektor → hitung kemiripan → ranking. Yang berubah hanya cara mengubah teks menjadi vektor.

PENERAPAN

Menerapkan NLP di Proses Kerja Anda

1

Identifikasi proses padat dokumen

invoice, laporan, email, feedback yang masih diolah manual.

2

Mulai dari yang kecil

regex & TF-IDF dari training ini sudah cukup untuk quick win.

3

Ukur dampaknya

waktu yang dihemat & kesalahan input yang berkurang.

4

Skalakan bertahap

model NLP / LLM dan integrasi ke sistem perusahaan.

CONTOH QUICK WIN DI AHM



Input data invoice & surat jalan otomatis



Analisis sentimen feedback pelanggan AHASS



Pencarian cepat SOP & dokumen internal



Ringkasan otomatis laporan harian

RANGKUMAN

Empat Hal untuk Diingat & Dipraktikkan

- ✓ NLP mengubah dokumen tidak terstruktur menjadi data siap analisis.
- ✓ AI memahami teks dengan mengubah kata menjadi angka (BoW, TF-IDF, embedding).
- ✓ Poin penting diambil lewat kata kunci, NER, dan peringkasan otomatis.
- ✓ TF-IDF + cosine similarity = mesin pencari untuk ribuan dokumen internal.



HANDS-ON SEKARANG

Jalankan 4 notebook praktik di Google Colab / Jupyter — satu untuk setiap materi:

Materi 1 · Ekstraksi Data
Materi 2 · AI Memahami Teks
Materi 3 · Poin Penting
Materi 4 · Pencarian Info

Latihan mandiri tersedia di akhir setiap notebook.